

Universidade do Minho
Escola de Engenharia

Sensorização Ambiente aplicada à Segurança Rodoviária

Sistema Autónomos
MEI - 4^o Ano - 2^o Semestre
Grupo 4

PG42818	Carolina Marques
PG42820	Constança Elias
PG42844	Maria Araújo Barbosa
A86271	Renata Ribeiro

14 de maio de 2021

Conteúdo

1	Introdução	4
1.1	Contextualização	4
1.2	Estrutura do Relatório	4
2	Análise e especificação dos requisitos	5
3	Arquitetura	6
4	Sensores e Colecionador	7
4.1	Sensores	7
4.2	Colecionador	7
4.3	Ambiente	9
4.4	Dados	9
5	Exploração e Tratamento de dados	10
6	Técnicas de visualização de dados	11
6.1	Geo-Visualização	12
6.2	Análise por Horas	13
7	Modelos preditivos	14
7.1	Decision Tree	14
8	Plataforma <i>Web</i>	15
9	Discussão dos Resultados	16
9.1	Avenida Central	16
9.2	Rotunda da Universidade	16
9.3	Rotunda da Estação	17
9.4	Lugar das Cabanas	17
9.5	Modelo Preditivo	18
10	Conclusão	20
A	Plataforma Web	21
B	Análise de Fluxo Tráfego por Horas	22

Lista de Figuras

3.1	Arquitectura da solução desenvolvida.	6
4.1	Localização dos pontos monitorizados	9
5.1	Pipeline do processamento de dados	10
6.1	Análise do Fluxo de Tráfego na Rotunda do Lugar das Cabanas	11
6.2	Demonstração da utilização de técnicas de geo-localização para representar os dados extraídos.	12
6.3	Desigualdade entre a velocidade média registada ao Domingo e Segunda feira na Rotunda da Universidade.	13
9.1	Media diária do freeFlowSpeed e currentSpeed ao longo do tempo.	17
9.2	Previsão de 24h do fluxo de tráfego na Avenida Central	18
9.3	Previsão de 24h do fluxo de tráfego na Rotunda das Cabanas	19
A.1	Tabela síntese dos resultados obtidos.	21
B.1	Variação do <i>current speed</i> numa segunda Feira.	22
B.2	Variação do <i>current travel time</i> numa segunda Feira.	23

Lista de Tabelas

9.1	Resultados obtidos na análise dos dados.	16
9.2	Valores obtidos na aplicação do modelo aos <i>datasets</i> escolhidos	18

Capítulo 1

Introdução

1.1 Contextualização

Com o aumento exponencial da densidade populacional nos grandes centros urbanos, são necessárias soluções inteligentes que permitam gerir e resolver, de forma eficiente e eficaz, todos os problemas subjacentes a estas cidades. Nesse sentido, a segurança rodoviária tornou-se num crescente ponto de preocupação da nossa sociedade, facilmente explicado pelo número substancial de acidentes e fatalidades que se verificam nas estradas, dia após dia.

Uma *Smart City*, ou Cidade Inteligente, deve ser capaz de responder a vários problemas, incluindo a segurança rodoviária, utilizando, para isso, sensores para coleção de dados, aplicando técnicas de fusão sensorial, e fazendo uso de modelos de *Machine Learning* capazes de prever fenómenos futuros.

Este trabalho foi desenvolvido no âmbito da unidade curricular de Sistemas Autónomos. O objectivo principal do projeto é a conceção e implementação de técnicas de sensorização de ambientes tirando partido da integração de sensores físicos e/ou virtuais.

1.2 Estrutura do Relatório

Este relatório divide-se em quatro partes principais:

- A primeira parte consiste na recolha dos dados utilizando colecionadores aplicados a sensores virtuais.
- Na segunda parte é apresentado o tratamento aplicado aos dados recolhidos.
- Em seguida mostramos as técnicas de visualização de dados utilizadas.
- A terceira corresponde à implementação de Modelos de *Machine Learning* para previsão e apresentação dos resultados obtidos.
- Por fim é feita uma breve síntese do trabalho realizado, apresentando as principais conclusões do mesmo.

Capítulo 2

Análise e especificação dos requisitos

O presente trabalho tem como objectivos a recolha de dados e a construção de uma plataforma que apresente os resultados da análise dos dados recolhidos em todos os pontos escolhidos pelo grupo. Tendo isso em conta, os principais requisitos são:

- A conceção de colecionadores de dados aplicados a sensores virtuais, focando cidades portuguesas. Os dados recolhidos devem ser relativos ao fluxo de tráfego rodoviário.
- A exploração e tratamento dos dados recolhidos, aplicando, entre outras, técnicas de geovisualização para análise dos dados geoespaciais colecionados;
- Desenvolvimento de um modelo de *Machine Learning* para previsão do tráfego nas várias coordenadas estudadas, permitindo a discussão das questões abordadas no contexto das unidades curriculares de Aprendizagem e Extração de Conhecimento, e Computação Natural.

Capítulo 3

Arquitetura

A arquitetura desta solução encontra-se representada, de forma sucinta, no esquema 3.1. Os dados, extraídos de uma API externa, foram submetidos a um processo de tratamento com o objetivo de os adaptar de acordo com os requisitos do enunciado. Depois do processamento, os dados encontram-se preparados para serem visualizados e apresentados na aplicação permitindo aos utilizadores acompanhar as condições diárias dos locais sujeitos a análise. Adicionalmente, o modelo de Machine learning implementado, permite estabelecer relações entre os dados e obter previsões relacionadas com o fluxo do tráfego futuro. Também estas previsões foram incluídas na plataforma final, permitindo ao utilizador observar graficamente as condições futuras.




Figura 3.1: Arquitectura da solução desenvolvida.

Capítulo 4

Sensores e Colecionador

4.1 Sensores

A equipa *TomTom Traffic* oferece uma ampla gama de aplicações. Para este projeto foi utilizado como sensor virtual a **Traffic API** da **TomTom Traffic Team**. Este sensor permite a análise em tempo real de tráfego para posteriormente, criar aplicativos e efetuar análises estatísticas relativas aos dados recolhidos.

O sensor utilizado oferece-nos, entre outras, as seguintes *features* referentes ao tráfego em tempo real num local específico:

- **Functional Road Class (FRC)**, que indica o tipo de estrada da qual estão a ser recolhidos os dados. Existem sete tipos (FRC0-FRC6), que incluem estradas principais, estradas secundárias, entre outras.
- **Current speed**, que indica a velocidade média em Km por hora.
- **Current travel time**, que indica o tempo necessário, em segundos, para cruzar os pontos definidos.
- **Free Flow speed**, que devolve a velocidade esperada em circunstâncias ideais.
- **Free Flow Travel Time**, que indica o tempo em segundos que seria esperado para percorrer a área definida pelas coordenadas em circunstâncias normais.
- **Confidence**, que mede a qualidade do tempo de viagem e da velocidade fornecidos.

4.2 Colecionador

O colecionador de dados desenvolvido trata-se de um *script* em **Python**. Este *script* faz um pedido à API da TomTom, usando uma chave API obtida aquando do registo na plataforma, e guarda os dados recebidos num ficheiro em formato JSON. A resposta do pedido à API toma o seguinte formato:

```
{
  "flowSegmentData": {
    "-xmlns": "http://lbs.tomtom.com/services",
    "-version": "traffic-service 2.0.004",
    "frc": "FRC2",
    "currentSpeed": 41,
```

```

    "freeFlowSpeed": 70,
    "currentTravelTime": 153,
    "freeFlowTravelTime": 90,
    "confidence": 0.59,
    "roadClosure": true,
    "coordinates": {
        "coordinate": [
            {
                "latitude": 52.40476,
                "longitude": 4.844318
            },
            {
                "latitude": 52.411312,
                "longitude": 4.8299975
            },
            {
                "latitude": 52.415073,
                "longitude": 4.827327
            }
        ]
    }
}
}
}

```

Listing 4.1: Função colecionadora os dados

O código 4.2 apresenta a função principal deste colecionador. Trata-se de uma função que recebe os dados adquiridos da API e altera-os para o formato desejado para o tratamento, guardando por fim o objeto resultante num ficheiro em formato JSON. O tratamento de dados feito consiste na adição do campo `timestamp`, para guardar a data e hora em que foram recolhidos, e na remoção do campo `coordinates`, que contém uma lista de coordenadas que descrevem a área que circunda o ponto de coordenadas passado no pedido à API.

```

def iterateOverResponse(dados):
    sttime = datetime.now().strftime('%Y-%m-%d_%H:%M:%S')
    savedResponses = dict()
    for attribute, value in dados['flowSegmentData'].items():
        if attribute == 'coordinates':
            break
        else:
            savedResponses['timestamp'] = sttime
            savedResponses[attribute] = value
    allresp.append(savedResponses)
    with open("data.json", 'a') as file:
        file.write(json.dumps(savedResponses) + '\n')

```

Listing 4.2: Função colecionadora os dados

Esta função encontra-se dentro de um ciclo *while*, com condição *True*, para executar constantemente. Uma vez que se mede estradas de diferentes graus de importância ou movimentação, o intervalo de tempo que determina os pedidos à API varia. Por exemplo, em estradas principais onde costuma haver mais trânsito é necessária recolher mais dados (com um intervalo de tempo menor) do que em estradas pouco movimentadas.

4.3 Ambiente

Com o objetivo de automatizar o processo de pedidos à API, recorreu-se ao ambiente de desenvolvimento *PythonAnywhere*, que é um serviço de hospedagem web baseado na linguagem de programação *Python*, para executar o *script* desenvolvido e previamente explicado.

4.4 Dados

Os dados recolhidos são relativos a quatro pontos diferentes da cidade de Braga, escolhidos de modo a pertencerem a estradas de diferentes tipos e ainda por serem locais com elevado fluxo de tráfego. Cada elemento do grupo ficou responsável por extrair os dados de um dos pontos seleccionados, inserindo as coordenadas do ponto a tratar no *script* que faz os pedidos à API. A recolha de dados teve início na semana de 26 de abril de 2021 e terminou no dia 13 de maio (3 dias antes da entrega do trabalho), de forma a maximizar os dados recolhidos para posterior análise. De seguida, apresenta-se a lista dos locais monitorizados. Dois dos pontos seleccionados são referentes a estradas principais (FRC2) e os outros dois são referentes a estradas secundárias (FRC3).

- FRC2: - Avenida Central: 41.53160534781263, -8.449663742370229
- FRC3 - Rotunda da Estação: 41.54912784933335, -8.434059568281395
- FRC3 - Lugar das cabanas (Rotunda da Taberna Belga): 41.56369642, -8.420025
- FRC2 - Rotunda da Universidade: 41.5601354,-8.4050806

Estes pontos encontram-se referenciados na figura 4.1.



Figura 4.1: Localização dos pontos monitorizados

Capítulo 5

Exploração e Tratamento de dados

Uma fase fundamental da realização deste projeto foi a análise e exploração dos dados recolhidos. Com isto torna-se possível delinear o processamento dos dados a ser feito para que nas etapas seguintes se consiga visualizar os dados e criar um modelo preditivo responsável por prever o fluxo de tráfego.

Assim, à medida que se extraíam os dados, analisou-se as respostas da API de modo a entender qual a informação relevante para a questão em análise. Converteu-se o tipo dos dados, passando os valores numéricos (que estavam a ser guardados como *string*) para inteiros. O `timestamp` foi adicionado a cada entrada do *dataset* pela necessidade futura de estabelecer uma relação entre as diferentes métricas e o horário/dia a que estas se referiam.

A figura 5.1 apresenta um esquema do *pipeline* do processamento dos dados.

As respostas do pedido à API vêm em formato JSON (definido no *script* responsável pelos pedidos à API) pelo que é necessário converter o ficheiro para CSV. Após essa conversão, corrige-se o formato do campo `timestamp`, com um script em *Python*. No meadamente, é feita a alteração da hora de modo a ficar em conformidade com o horário de Portugal.

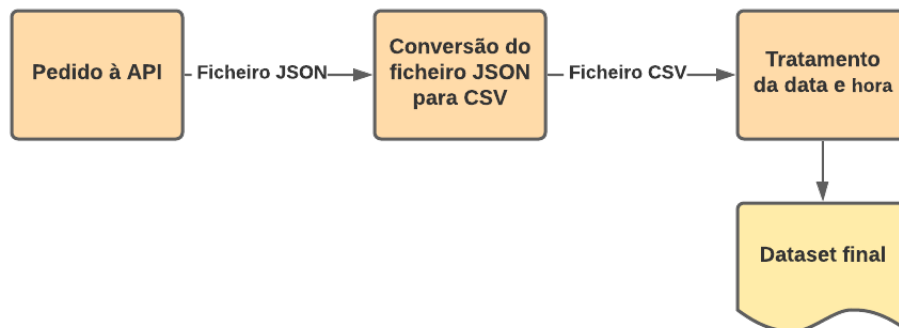


Figura 5.1: Pipeline do processamento de dados

Capítulo 6

Técnicas de visualização de dados

Para a visualização dos dados utilizou-se o **Google Data Studio**, por ser intuitivo, gratuito e permitir obter *dashboards* visuais muito completas.

Para cada ponto monitorizado criou-se um relatório, que mostra 4 gráficos diferentes:

- Média diária do *currentTravelTime* e *freeFlowTravelTime* ao longo do tempo;
- Média diária do *freeFlowSpeed* e *currentSpeed* ao longo do tempo;
- Relação entre o *currentTravelTime* e *CurrentSpeed*;
- Variação do valor de Confiança.

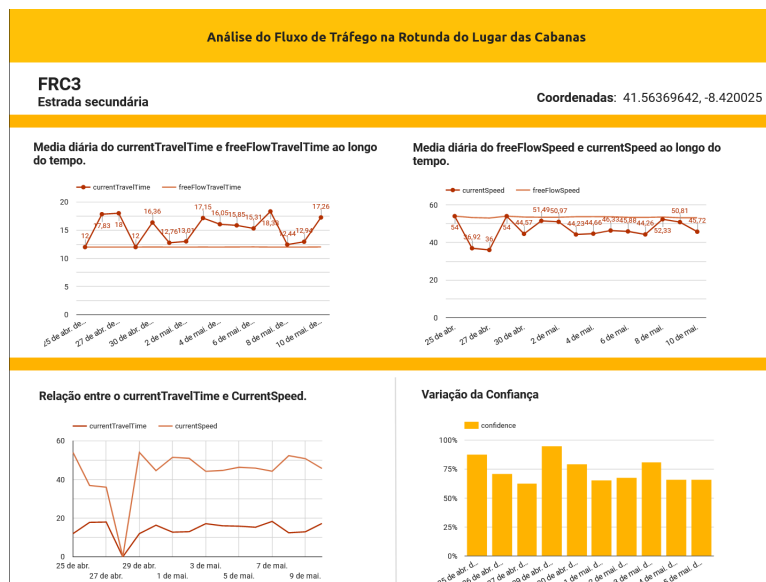


Figura 6.1: Análise do Fluxo de Tráfego na Rotunda do Lugar das Cabanas

Estes gráficos possibilitam a comparação dos resultados entre os diferentes pontos.

Para além disso existem mais 4 relatórios que combinam os dados dos diferentes pontos, tornando mais fácil comparar os vários valores recolhidos.

- Um relatório apresenta o número total de valores recolhidos para cada ponto em cada dia, ou seja o número de pedidos realizado a API;
- O segundo relatório, de Geo-Visualização, contém um mapa que relaciona o valor médio do *travel time* e da *velocidade* ao longo do dia;
- O terceiro analisa o fluxo de tráfego por horas (neste caso a *Current Speed*), para todos os pontos, permitindo seleccionar o dia da semana; (exemplo em B)
- O último explora o fluxo de tráfego, através da variação da métrica *Current Travel Time*. (exemplo em B)

6.1 Geo-Visualização

A integração da Geo-visualização mostrou-se útil por dar ao utilizador uma noção da localização dos pontos monitorizados no mapa. Esta representação foi enriquecida ao adicionar-se, para os vários períodos do dia, uma variação de cor no local monitorizado, de acordo com a velocidade média do trânsito e ainda a variação do tamanho do círculo que aumenta à medida que o tempo de espera se torna mais elevado.

A figura 6.2 exhibe o comportamento do gráfico quando se fixa o horário às 20h.



Figura 6.2: Demonstração da utilização de técnicas de geo-localização para representar os dados extraídos.

6.2 Análise por Horas

As últimas páginas mencionadas, referem-se à análise da velocidade atual e do tempo de viagem ao longo do dia nos diferentes pontos analisados. Os gráficos desenvolvidos possuem um filtro que permite ao utilizador escolher o(s) dia(s) da semana que pretende analisar, proporcionando a comparação do fluxo de tráfego em diferentes dias. Por exemplo, verificar a relação entre a segunda-feira e a terça-feira ou simplesmente procurar confirmar a diferença do fluxo de tráfego ao fim de semana quando comparado com dias úteis.

O gráfico da figura 6.3 revela a desigualdade entre a velocidade atingida ao domingo e a Segunda - feira na rotunda da universidade.




Figura 6.3: Desigualdade entre a velocidade média registada ao Domingo e Segunda-feira na Rotunda da Universidade.

Sabendo que ao Domingo não existem actividades lectivas é espectável que se verifique pouco volume de tráfego neste ponto. Por outro lado, na segunda-feira espera-se que o tráfego em determinados horários seja intenso provocando uma diminuição da velocidade. Com a análise do gráfico, as conjecturas anteriores confirmam-se pois verifica-se que ao domingo a velocidade é constante, possuindo valores a rondar os 43 Km/hora. Em oposição, às segundas-feiras, por volta das 8:00h, 12:00h e 17:00h, a velocidade sofre uma grande diminuição face ao aumento de circulação automóvel.

Capítulo 7

Modelos preditivos

7.1 Decision Tree

As árvores de decisão são modelos de regressão linear que tendem a ser o método de escolha para a modelação preditiva pois são relativamente fáceis de compreender e também muito eficazes. O objectivo básico de uma árvore de decisão é dividir uma população de dados em segmentos mais pequenos. Uma árvore de regressão é usada para prever dados quantitativos contínuos. Para criar o modelo de previsão do fluxo de tráfego, decidimos usar o algoritmo *Decision Tree*, baseado nas árvores de decisão. Pelo que foi dito anteriormente, conclui-se que este modelo de regressão linear seria o mais adequado para a previsão que pretendíamos fazer.

Para se poder aplicar este algoritmo ao *dataset* previamente tratado, foi necessário fazer um pré-processamento. Primeiro, retiraram-se os minutos do campo `timestamp`, uma vez que se pretende fazer o cálculo por horas e agrupou-se os dados do *dataset* por horas. Dividiu-se, de seguida, o *dataset* para treino e teste (70% para treino e 30% para teste). Posteriormente, normalizou-se os dados, de modo a utilizar a mesma escala (entre 0 e 1).

Após este tratamento, foi aplicado o modelo *Decision Tree*. Este modelo obteve, em média, 94.75% de acurácia.

Capítulo 8

Plataforma *Web*

Após o tratamento e visualização dos dados nos capítulos anteriores, vamos agora explicar o desenvolvimento da plataforma *web*. Esta plataforma foi desenvolvida no *Google Sites*, devido à facilidade de integração dos *dashboards* desenvolvidos no *Google Data Studio*. A estrutura definida para esta plataforma foi pensada tendo em conta a finalidade deste projeto: a necessidade de análise e previsão do fluxo de tráfego.

A aplicação foi desenvolvida tendo em conta os possíveis clientes que esta poderia ter. Os resultados apresentados na aplicação poderão vir a ser úteis, por exemplo, à Câmara Municipal de Braga, dando-lhe a capacidade de tomar decisões relacionadas com as faixas de rodagem do município.

Como foi referido anteriormente, neste trabalho apenas nos focámos na análise de quatro locais da cidade. No entanto, facilmente se expande a análise realizada para outros locais de interesse para o município. Assim, para cada local seleccionado, serão fornecidas varias informações, nomeadamente:

- Os horários em que a velocidade é maior;
- A velocidade media em cada local;
- A velocidade média nos próximos dias;
- O tempo de passagem por um dado local é superior ao esperado;
- O tempo que os habitantes ou visitantes terão de dispensar para passar por um determinado local;

Munido destes dados, o município pode tomar várias decisões: determinar o horário mais adequado para realizar obras que perturbem a circulação (ou seja, o horário em que a velocidade é superior o que significa que o volume de tráfego é menor), determinar se num dado local é necessário recorrer a radares para promover uma diminuição da velocidade ou ainda avaliar a necessidade de alargar a faixa de rodagem se verificar que o trânsito se encontra lento diariamente.

A plataforma pode ser acedida no seguinte endereço: <https://sites.google.com/view/sa-grupo4/in%C3%ADcio>.

Capítulo 9

Discussão dos Resultados

Nesta secção iremos apresentar os principais resultados obtidos da análise e visualização dos dados. A tabela 9.1 apresenta as horas com maior trânsito de cada ponto e os valores médios da *Current Speed* e do *Current Travel Time* ao longo dos dias recolhidos.

	<i>Horas de Maior Trânsito</i>	<i>Current Speed</i>	<i>Current Travel Time</i>
Avenida Central	8h-9h e 17h-18h	45.1	79.3
Rotunda da Universidade	6h-9h e 16h-20h	32	45.8
Lugar das Cabanas	7h-9h e 15h e 17h	46.4	15.6
Rotunda da Estação	6h-9h e 15h-18h	35.5	91.3

Tabela 9.1: Resultados obtidos na análise dos dados.

9.1 Avenida Central

Nesta Avenida, os valores por defeito para o *Current Speed* e para o *Current Travel Time* nesta estrada são 48 e 70, respetivamente. Como se observa na tabela, os valores médios para o *Current Speed* são muito próximos dos valores desta em condições ideais. Os valores médios para *Current Travel Time* são mais altos do que o esperado em circunstâncias normais, querendo isto dizer que em média o tempo necessário para percorrer a área definida pelas coordenadas é mais alto, podendo portanto concluir ainda que o tráfego naquela zona foi maior do que o esperado. Nota-se ainda que as horas onde existe mais tráfego correspondem ao início e ao fim do horário laboral.

9.2 Rotunda da Universidade

Os valores por defeito para o *Current Speed* e para o *Current Travel Time* nesta estrada são 44 e 38 respetivamente. Os dados recolhidos permitiram averiguar que as horas de maior trânsito corresponde ao período das 6h-9h e das 16h-20h de dias úteis (coincidido com as horas de início e fim das aulas).

9.3 Rotunda da Estação

Neste local, os valores por defeito de *current speed* e *current travel time* são aproximadamente 43 e 62, respetivamente. Como podemos observar da tabela 9.1, as horas de maior trânsito são entre as 6h e as 9h da manhã e a 15 e as 18h da tarde, a velocidade média é de 35,5 Km/h e o tempo médio necessário a percorrer a área é de 91,3 segundos. Em comparação com os valores que seriam obtidos em situações ideais, estes são um pouco divergentes.

Como podemos observar da figura 9.1, nos dias 1,2,8 e 9 ,que dizem respeito aos fim-de-semanas, a velocidade é maior e bem mais próxima do valor que se obteria em condições ideais. Aqui podemos ver claramente que o tráfego/congestão diminui significativamente durante os fim-de-semanas, sendo que durante a semana e principalmente no horário de trabalho, verifica-se o oposto.




Figura 9.1: Media diária do freeFlowSpeed e currentSpeed ao longo do tempo.

A variável *current speed* e *current travel time* têm uma relação proporcional como seria espectável e é facilmente confirmado analisando os máximos e os mínimos obtidos. Para as velocidades, foi registado um valor de mínimo e máximo de 6 Km/hora e 44Km/h, pelo que para o tempo percorrido foi registado um total mínimo de 62 segundos e máximo de 456 segundos (aproximadamente 7 minutos).

9.4 Lugar das Cabanas

Realizando um estudo dos dados obtidos e dos gráficos desenvolvidos percebe-se que a velocidade média neste local é de 46,4 Km/hora, o valor mínimo registado foi de 7 km/hora tendo-se verificado ainda em algum momento uma velocidade de 54 km/hora o que representa excesso de velocidade para a estrada em questão. Como era de esperar, o *current Travel time* varia proporcionalmente com a variação do *current speed*, cujo valor médio é 15.6 segundos atingindo um tempo máximo de espera de 98.0 segundos. Os valores extraídos apresentam um confiança de 70%.

9.5 Modelo Preditivo

A tabela 9.2 apresentada os valores de acurácia e desvio padrão obtidos para cada estrada medida.

	Acurácia	Desvio Padrão
Avenida Central	97%	0.04
Rotunda da Universidade	95%	0.06
Lugar das Cabanas	93%	0.21
Rotunda da Estação	94%	0.05

Tabela 9.2: Valores obtidos na aplicação do modelo aos *datasets* escolhidos

Para análise dos resultados, a figuras 9.2 e Figura 9.3 apresentam um gráfico que permite comparar os valores reais de trânsito com os valores de tráfego previstos pelo modelo em 24 horas. Este dados são referentes à Avenida Central e Rotunda da Cabanas, respetivamente. O eixo dos x apresenta o acumular do número de horas desde o início da medição, sendo que o gráfico apresenta valores referentes a dois dias (48h). O eixo dos y apresenta os valores da velocidade atual, em km/h.

A figura 9.2 apresenta três conjuntos de valores. A linha verde clara apresenta os valores de velocidade das 24h de um dos dias do *dataset*. Estes valores estão compreendidos entre 31 a 48 km/h. As 24h horas seguintes apresentam dois tipos de valores: a linha verde escura apresenta os valores reais da velocidade nessas horas (compreendidos entre os 10 e 48 km/h); a linha a tracejado apresenta os valores previstos pelo modelo para essas mesmas 24 horas. Estes valores estão compreendidos entre os 27 km/h e os 48 km/h. Este é conjunto de dados para o qual o modelo apresenta maior acurácia, sendo que o único desvio que existe em relação aos valores reais é o que existe ao fim de 41 horas após o início da contagem das horas.




Figura 9.2: Previsão de 24h do fluxo de tráfego na Avenida Central

A figura 9.3 apresenta os resultados da aplicação do modelo na Rotunda das Cabanas. A velocidade neste lugar apresenta uma maior variação, sendo que os valores variam entre os 10 km/h e os 53 km/h. Neste caso o modelo não preveu tão bem os valores sendo que este teve tendência a prever velocidades ligeiramente mais altas do que as velocidades reais e apresentou apenas dois desvios maiores: um após 24 horas e outro após 37 horas (desde o início da contagem).




Figura 9.3: Previsão de 24h do fluxo de tráfego na Rotunda das Cabanas

Capítulo 10

Conclusão

Depois do trabalho finalizado, importa estabelecer algumas considerações, nomeadamente no que se refere às decisões de implementação. A escolha do ambiente para execução do *script* de chamadas à API, *PythonAnywhere*, não foi a melhor escolha, por estar sempre a interromper (após um determinado número de horas). Se dispuséssemos desta informação de antemão teria-se optado por usar outro servidor, como a **Google Cloud**. Para além disso, *PythonAnywhere* exigiu a definição extra de um *script* para acertar a hora, pois a hora devolvida no campo `timestamp` era uma hora inferior ao fuso horário de Portugal atual (GMT+1).

Por outro lado, a escolha do formato para armazenamento dos dados também não foi a melhor. Uma vez que os dados utilizados para análise no **Google Data Studio** tinham de estar guardados num ficheiro em formato CSV, poderia-se ter optado por recolher logo os dados para um ficheiro com este formato (em vez do formato JSON), no sentido de facilitar o processo de processamento dos dados.

No que se refere à recolha dos dados, poderia-se ter começado a recolher os dados mais cedo para obter um maior *dataset* e, conseqüentemente, poder obter melhores resultados e mais credíveis (a nível das previsões por exemplo). Consideramos, no entanto, que o conjunto de dados recolhido já permitiu tirar boas conclusões, uma vez que são dados de quase 3 semanas.

Em relação aos resultados, os dados analisados, tornam evidente que na cidade de Braga o fluxo de tráfego se torna mais expressivo durante os dias úteis no período das 9h e das 18h, correspondendo aos horários em que os Bracarenses se deslocam para o seu trabalho e vice versa.

A nível de trabalho futuro, seria interessante integrar dados relativos à meteorologia para avaliar de que forma é que influenciam o fluxo de tráfego. Para além disso, valorizaria o trabalho a expansão da análise deste tipo de dados para grandes áreas metropolitanas, com muito trânsito, como Lisboa e Porto, estabelecendo uma comparação entre os resultados obtidos. Inserir na aplicação web uma funcionalidade que permita prever o trânsito, num dado local, para uma determinada hora do dia enriqueceria bastante a plataforma desenvolvida.

Apêndice A

Plataforma Web

Neste anexo realçamos alguns gráficos e tabelas presentes na plataforma web em <https://sites.google.com/view/sa-grupo4/in%C3%ADcio>.




Figura A.1: Tabela síntese dos resultados obtidos.

Apêndice B

Análise de Fluxo Tráfego por Horas




Figura B.1: Variação do *current speed* numa segunda Feira.

Current Travel Time


Rotunda da Universidade (FRC2)



Avenida Central (FRC2)



Rotunda do Lugar das Cabanas (FRC3)



Rotunda da Estação (FRC3)




Figura B.2: Variação do *current travel time* numa segunda Feira.